

Laboratório 02 — Processamento de Bases de Dados em Lote

Ana Clara Ivanof de Oliveira

Arquivo PDF correspondente ao QMD da atividade. Os resultados e calendários são produzidos na compilação com o arquivo flights.csv.zip, conforme o caminho relativo indicado no QMD.

title: "Laboratório 02 - Processamento de Bases de Dados em Lote"

author: "Ana Clara Ivanof de Oliveira"

format:

pdf:

toc: false

number-sections: true

execute:

echo: true

warning: false

message: false

1. Estatísticas suficientes

Para calcular o percentual de voos com `ARRIVAL_DELAY > 10`, para cada combinação de dia, mês e companhia aérea, são suficientes duas informações: o número total de voos válidos e o número de voos com atraso superior a 10 minutos. O percentual final é obtido por `atrasos / total`.

2. Função getStats

```
library(dplyr)
library(readr)

getStats <- function(input, pos) {
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(
      !is.na(AIRLINE),
      !is.na(MONTH),
      !is.na(DAY),
      !is.na(ARRIVAL_DELAY)
    ) %>%
    group_by(AIRLINE, MONTH, DAY) %>%
    summarise(
      total = n(),
      atrasos = sum(ARRIVAL_DELAY > 10),
      .groups = "drop"
    )
}
```

3. Leitura em lotes

O arquivo é lido em lotes de 100.000 registros. Apenas as quatro colunas necessárias para a atividade são importadas.

```
colunas <- cols_only(
  AIRLINE = col_character(),
  MONTH = col_integer(),
  DAY = col_integer(),
  ARRIVAL_DELAY = col_double()
)

lotes <- read_csv_chunked(
  file = file.path("../dados", "flights.csv.zip"),
```

```

callback = DataFrameCallback$new(getStats),
chunk_size = 100000,
col_types = colunas
)

```

4. Função computeStats

```

computeStats <- function(stats) {
  stats %>%
    group_by(AIRLINE, MONTH, DAY) %>%
    summarise(
      total = sum(total),
      atrasos = sum(atrasos),
      .groups = "drop"
    ) %>%
    mutate(
      Cia = AIRLINE,
      Data = as.Date(
        paste(2015, MONTH, DAY, sep = "-")
      ),
      Perc = atrasos / total
    ) %>%
    select(Cia, Data, Perc)
}

stats <- computeStats(lotes)
stats

```

5. Calendários

```

library(ggplot2)
library(ggcal)

pal <- scale_fill_gradient(
  low = "#4575b4",
  high = "#d73027"
)

baseCalendario <- function(stats, cia) {
  dados <- stats %>%
    filter(Cia == cia)

  ggcal(dados$Data, dados$Perc)
}

cAA <- baseCalendario(stats, "AA")
cDL <- baseCalendario(stats, "DL")
cUA <- baseCalendario(stats, "UA")
cUS <- baseCalendario(stats, "US")

```

American Airlines — AA

```
cAA + pal + ggtitle("Percentual de atrasos - AA")
```

Delta Air Lines — DL

```
cDL + pal + ggtitle("Percentual de atrasos - DL")
```

United Airlines — UA

```
cUA + pal + ggtitle("Percentual de atrasos - UA")
```

US Airways — US

```
cUS + pal + ggtitle("Percentual de atrasos - US")
```

Horário de compilação

```

Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()

```