

Laboratório 03 — Dados relacionais e operações do tipo join

Ana Clara Ivanof de Oliveira

title: "Laboratório 03 - Dados relacionais e operações do tipo join"

author: "Ana Clara Ivanof de Oliveira"

format: pdf

execute:

echo: true

Pacotes

```
library(dplyr)
library(readr)
library(leaflet)
```

1. Importação dos arquivos

```
airports <- read_csv(
  "../dados/airports.csv",
  col_types = cols_only(
    IATA_CODE = col_character(),
    CITY = col_character(),
    STATE = col_character(),
    LATITUDE = col_double(),
    LONGITUDE = col_double()
  )
)

airlines <- read_csv("../dados/airlines.csv", col_types = cols())
```

2. Leitura de flights em lotes

As estatísticas suficientes para a média são o número de observações válidas e a soma dos atrasos.

```
getStats <- function(input, pos) {
  input %>%
    filter(!startsWith(DESTINATION_AIRPORT, "1")) %>%
    filter(!is.na(DESTINATION_AIRPORT),
           !is.na(ARRIVAL_DELAY)) %>%
    group_by(DESTINATION_AIRPORT) %>%
    summarise(
      n = n(),
      soma_atraso = sum(ARRIVAL_DELAY),
      .groups = "drop"
    )
}

colunas <- cols_only(
  DESTINATION_AIRPORT = col_character(),
  ARRIVAL_DELAY = col_double()
)

flights_chunks <- read_csv_chunked(
  "../dados/flights.csv.zip",
  callback = DataFrameCallback$new(getStats),
  chunk_size = 1000000,
  col_types = colunas
)
```

3. Média de atraso por aeroporto

```
flights_stats <- flights_chunks %>%
  group_by(DESTINATION_AIRPORT) %>%
  summarise(
    n = sum(n),
    soma_atraso = sum(soma_atraso),
    atraso_medio = soma_atraso / n,
    .groups = "drop"
  )

flights_stats
```

4. Chaves e aeroportos ausentes

A chave de `flights` é `DESTINATION\_AIRPORT`. A chave de `airports` é `IATA\_CODE`.

```
aeroportos_ausentes <- flights_stats %>%
  anti_join(
    airports,
    by = c("DESTINATION_AIRPORT" = "IATA_CODE")
  )

aeroportos_ausentes
```

5. Join com airports

```
flights <- flights_stats %>%
  left_join(
    airports %>% select(IATA_CODE, CITY, STATE, LATITUDE, LONGITUDE),
    by = c("DESTINATION_AIRPORT" = "IATA_CODE")
  )

flights
```

6. Quantidade de aeroportos por estado

```
aeroportos_por_estado <- airports %>%
  filter(!is.na(STATE)) %>%
  count(STATE, name = "n_aeroportos") %>%
  arrange(desc(n_aeroportos))

aeroportos_por_estado
```

7. Mapa dos atrasos por aeroporto

```
this <- flights %>%
  filter(!is.na(LATITUDE), !is.na(LONGITUDE)) %>%
  leaflet() %>%
  addTiles() %>%
  addMarkers(
    lng = ~LONGITUDE,
    lat = ~LATITUDE,
    popup = ~paste0(
      "<b>Aeroporto:</b> ", DESTINATION_AIRPORT,
      "<br><b>Cidade:</b> ", CITY,
      "<br><b>Estado:</b> ", STATE,
      "<br><b>Atraso médio:</b> ", round(atraso_medio, 2), " minutos"
    )
  )

this
```

Compilação

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```